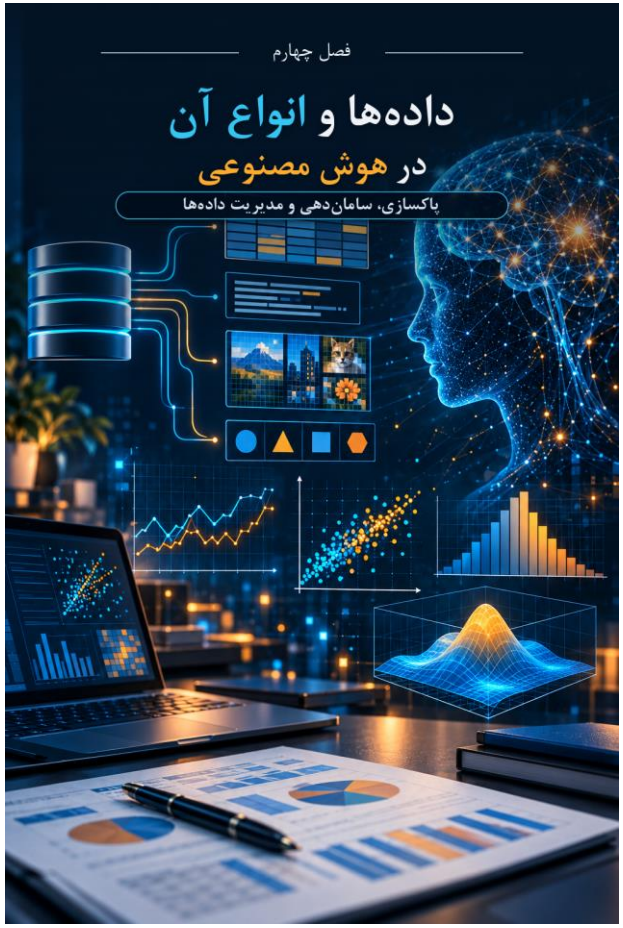
اهداف



- ✓ آشنایی با داده‌ها
- ✓ آشنایی با پایگاه‌های داده موجود
- ✓ شناخت چالش‌ها و محدودیت‌های داده‌ها و پایگاه‌ها
- ✓ پاکسازی داده‌ها
- ✓ سامان‌دهی داده‌ها
- ✓ نمایش و مدیریت داده‌ها

داده‌های تجربی

- ✓ داده‌های تجربی، اطلاعاتی هستند که از طریق آزمایش‌ها و اندازه‌گیری‌های مستقیم از مواد و رفتار آن‌ها در شرایط مختلف به‌دست می‌آیند.
- ✓ یکی از انواع اصلی داده‌های تجربی، داده‌هایی است که از ویژگی‌های فیزیکی و مکانیکی مواد بدست می‌آید. این داده‌ها شامل استحکام، سختی، انعطاف‌پذیری، چقرمگی، کشش و مقاومت به فشار و دما است. آزمایش‌هایی مانند آزمایش کشش، آزمایش فشار، آزمایش خستگی و آزمایش ضربه برای جمع‌آوری این داده‌ها به‌کار می‌روند.
- ✓ از سوی دیگر داده‌هایی که از میکروسکوپ‌های الکترونی (SEM/TEM) یا میکروسکوپ‌های نیروی اتمی (AFM) به‌دست می‌آیند، اطلاعات دقیقی از ساختار میکروسکوپی و نانوساختار مواد را ارائه می‌دهند.
- ✓ این داده‌ها برای شبیه‌سازی رفتار مواد در مقیاس میکروسکوپی و نانو، بررسی مورفولوژی سطحی و تحلیل رفتار مواد در مقیاس میکرو یا نانو استفاده می‌شوند.

داده‌های شبیه‌سازی‌شده

- ✓ داده‌های شبیه‌سازی‌شده اطلاعاتی هستند که از طریق مدل‌های ریاضی و شبیه‌سازی‌های کامپیوتری به‌دست می‌آیند.
- ✓ داده‌های شبیه‌سازی‌شده امکان پیش‌بینی رفتار مواد تحت شرایط مختلف را قبل از انجام آزمایش‌های فیزیکی فراهم می‌کنند.
- ✓ بطور مثال شبیه‌سازی‌های مبتنی بر نظریه تابع چگالی (DFT) یا (Density Functional Theory) برای تحلیل و پیش‌بینی خواص الکترونی مواد استفاده می‌شوند.
- ✓ شبیه‌سازی‌های دینامیکی مولکولی به شبیه‌سازی حرکت اتم‌ها و مولکول‌ها در طول زمان پرداخته و می‌توانند برای تحلیل رفتار مواد در مقیاس نانو استفاده شوند.
- ✓ در شبیه‌سازی‌های مبتنی بر مکانیک پیوسته، مواد به بخش‌های کوچک (المان) تقسیم شده و رفتار آن‌ها تحت تأثیر نیروهای خارجی بررسی می‌شود. این مدل‌ها معمولاً برای شبیه‌سازی‌های مکانیکی، حرارتی و الکتریکی در مهندسی مواد کاربرد دارند.

داده‌های متنی

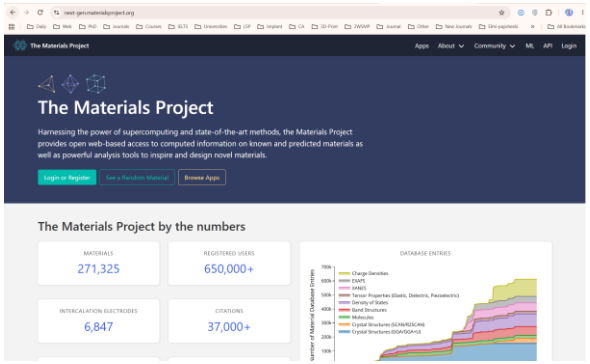
- ✓ منابع متنی شامل مقالات ژورنالی، پایان‌نامه‌ها، گزارش‌های فنی و اسناد پتنت هستند. هدف از استخراج متنی این است که اطلاعات **پراکنده** را به داده **ساخت‌یافته** تبدیل کرد.
- ✓ این اطلاعات می‌تواند نام و فرمول مواد، شرایط ساخت مانند دما و زمان و اتمسفر، روش‌های آزمون، مقادیر عددی خواص همراه با واحد و عدم‌قطعیت و نیز نتایج عملکرد باشد.
- ✓ فرآیند کار معمولاً چنین پیش می‌رود که ابتدا اسناد از پایگاه‌های علمی یا وبگاه‌های پتنت گردآوری می‌شود. سپس متن جمله‌بندی می‌شود و بخش‌های مهم شناسایی می‌شوند. در گام بعد، روابط میان بخش‌ها استخراج می‌شود تا هر مقدار عددی به ماده و شرایط مربوط وصل شود. همسان‌سازی واحدها و نام‌ها اهمیت زیادی دارد. برای نمونه، K و °C باید به یک دستگاه واحد تبدیل شود و صورت‌های مختلف نام یک ماده به یک **شناسه یکتا** نگاشت شود.
- ✓ کیفیت استخراج داده‌ها همواره بایستی سنجیده و مستند شود. بهتر است کنار هر سری داده، بخشی از متن منبع و شماره صفحه نگهداری شود تا امکان بازبینی وجود داشته باشد.
- ✓ از نظر حقوقی و اخلاقی باید به **مجوز** استفاده از متن‌ها توجه شود. متن پتنت‌ها معمولاً عمومی است با این حال نقل قول و ارجاع دقیق لازم است. در نهایت، خروجی استخراج باید در قالبی ساخت‌یافته مانند فرآیند، خاصیت، مقدار، واحد، شرایط، منبع و اعتماد به کار رود تا در مراحل بعدی مدل‌سازی قابل استفاده باشد.

داده‌های ترکیبی و اشتقاقی

- ✓ داده‌های ترکیبی به مجموعه‌هایی گفته می‌شود که اطلاعات **آزمایشگاهی و محاسباتی** را کنار هم می‌گذارند تا پوشش و دقت افزایش یابد. برای نمونه، انرژی‌های تشکیل محاسبه شده می‌تواند در کنار اندازه‌گیری‌های کالری‌متری قرار گیرد تا تصویری یکنواخت از پایداری فازی ساخته شود. در واقع داده‌های کم‌هزینه و پرحجم از شبیه‌سازی‌ها و داده‌های گران‌قیمت و کم‌حجم از آزمایش‌ها در کنار هم استفاده می‌شوند.
- ✓ داده‌های اشتقاقی داده‌هایی هستند که از روی داده خام یا ترکیب چند منبع محاسبه می‌شوند. به عنوان نمونه محاسبه مدول یانگ از منحنی تنش–کرنش، اندازه دانه از روی تصویر ریزساختار، میانگین الکترونگاتیویته و شعاع یونی از ترکیب شیمیایی یا ساخت یک برچسب طبقه‌بندی مانند پایدار و ناپایدار بر اساس آستانه انرژی است. این برچسب‌های محاسبه‌شده باید همراه با روش محاسبه و عدم‌قطعیت گزارش شوند تا ارزیابی منصفانه باشد.

داده‌های ترکیبی و اشتقاقی

- ✓ در ادغام داده چند نکته کلیدی وجود دارد که باید مورد توجه قرار گیرد:
- ✓ **نخست**، هم‌ترازی تمامی رکوردهای داده اهمیت پیدا می‌کند. باید روشن باشد که کدام مقدار محاسباتی واقعاً به همان ماده یا همان شرایط آزمایش تعلق دارد.
- ✓ **دوم**، ناسازگاری روش‌ها باید مدیریت شود. استفاده از تابع‌های محاسباتی متفاوت یا پروتکل‌های آزمایشی ناهمسان می‌تواند به جابجایی سیستماتیک منجر شود. در این صورت یک تابع کالیبراسیون یا مدل سلسله‌مراتبی می‌تواند اختلاف را جبران کند.
- ✓ **سوم**، عدم‌قطعیت باید منتقل شود. اگر یک مقدار از ترکیب چند منبع به دست آمده است، عدم‌قطعیت نهایی باید اثر عدم‌قطعیت هر جزء را منعکس کند. در تولید داده اشتقاقی باید از دور باطل پرهیز کرد. اگر ویژگی‌ها از روی داده‌ای ساخته شده‌اند که بعداً همان داده هدف را تعریف می‌کند، خطر نشت مفهومی و برآورد بیش از حد عملکرد ایجاد می‌شود.
- ✓ **آخر**، آستانه‌ها و قواعدی که برای ساخت برچسب‌ها به کار می‌رود باید شفاف و قابل بازتولید باشد. نگهداری داده خام در کنار نسخه پردازش‌شده و ثبت دقیق کدها و پارامترها، کیفیت و اعتماد به نتایج را بالا می‌برد. خروجی ادغام و اشتقاق بهتر است با برچسب‌های روش و منبع ذخیره شود. برای هر رکورد مشخص کنید که منبع آن آزمایش، محاسبه یا ترکیبی است، روش دقیق چه بوده است و چه کالیبراسیونی اعمال شده است. این شفافیت به تصمیم‌گیری درست درباره تقسیم‌بندی، وزن‌دهی و ارزیابی کمک می‌کند.



منابع داده‌های مواد

پایگاه‌های داده عمومی

۱. پروژه مواد (Materials Project)

- ✓ این پایگاه، اطلاعات گسترده‌ای در زمینه مواد **سرامیکی، فلزی و نیمه‌رساناها** فراهم می‌کند. پروژه مواد یکی از مهم‌ترین پایگاه‌های داده در زمینه علم مواد است که اطلاعات مربوط به ترکیب‌های مختلف مواد و خواص آنها را جمع‌آوری و منتشر می‌کند.
- ✓ پروژه مواد همچنین اطلاعاتی در مورد **خواص مکانیکی مواد** (مانند استحکام کششی، سختی، و چقرمگی) و **خواص حرارتی** (مانند هدایت حرارتی و انبساط حرارتی) نیز فراهم می‌آورد. این پایگاه داده داده‌هایی از شبیه‌سازی‌های محاسباتی پیشرفته مانند نظریه عملکرد **دنیای تابع چگالی** (DFT) ارائه می‌دهد که به محققان این امکان را می‌دهد که بدون انجام آزمایش‌های **فیزیکی**، رفتار مواد را پیش‌بینی کنند.
- ✓ پروژه مواد دسترسی رایگان به داده‌های خود از طریق وب‌سایت خود ارائه می‌دهد و همچنین ابزارهایی مانند (Materials API) و (Materials Explorer) را برای جستجو و تجزیه و تحلیل داده‌ها فراهم کرده است. این ابزارها به محققان و مهندسان این امکان را می‌دهند که داده‌ها را به‌طور مؤثری بررسی کرده و از آن‌ها در پروژه‌های خود استفاده کنند.

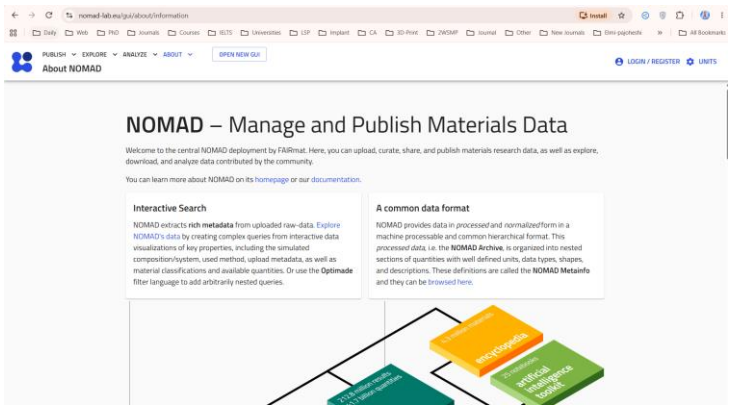
منابع داده‌های مواد

پایگاه‌های داده عمومی

۲. پایگاه داده کوانتومی باز مواد



- ✓ پایگاه OQMD (Open Quantum Materials Database) پایگاه داده‌ای است که اطلاعات مربوط به مواد مختلف و پیش‌بینی‌های محاسباتی درباره خواص آن‌ها را ارائه می‌دهد. این پایگاه داده بر **مواد معدنی و آلیاژهای فلزی** متمرکز است.
- ✓ این پایگاه شامل داده‌های **شبیه‌سازی‌شده** مبتنی بر نظریه عملکرد **دنیای تابع چگالی** (DFT) است که به‌طور خاص برای بررسی ویژگی‌های **الکترونیکی، ساختاری و حرارتی** مواد طراحی شده است.
- ✓ دسترسی به داده‌های (OQMD) از طریق وب‌سایت آن امکان‌پذیر است و ابزارهایی برای جستجوی داده‌ها و تجزیه و تحلیل آن‌ها فراهم شده است.



منابع داده‌های مواد

پایگاه‌های داده عمومی

۳. آزمایشگاه کشف مواد نوین

- ✓ پایگاه NOMAD (Novel Materials Discovery) پایگاه داده اطلاعاتی در خصوص مواد و خواص آن‌ها، علی‌الخصوص در زمینه **مواد نانو و جدیدترین پیشرفت‌های علمی در این حوزه**، در اختیار کاربران قرار می‌دهد. این پایگاه داده شامل داده‌های **شبیه‌سازی‌شده** بر اساس روش‌های کوانتومی مانند DFT و همچنین داده‌های **تجربی** از منابع مختلف است. داده‌هایی چندبعدی از خواص مختلف مواد مانند خواص مکانیکی، الکترونیکی، نوری و شیمیایی را ذخیره کرده و آن‌ها را در قالب پایگاه داده‌هایی سازمان‌دهی می‌کند.
- ✓ دسترسی آزاد به داده‌های خود را از طریق وب‌سایت رسمی فراهم کرده است و ابزارهای تجزیه و تحلیل پیشرفته برای استفاده از این داده‌ها در اختیار پژوهشگران قرار می‌دهد.

NOMAD
NOVEL MATERIALS DISCOVERY

منابع داده‌های مواد

ب) پایگاه‌های داده آزمایشگاهی

- ✓ علاوه بر پایگاه‌های داده عمومی، بسیاری از دانشگاه‌ها و موسسات تحقیقاتی نیز داده‌های خود را در پایگاه‌های داده اختصاصی نگهداری می‌کنند. این داده‌ها معمولاً شامل نتایج آزمایش‌ها، شبیه‌سازی‌ها و تحقیقات منتشر نشده هستند که در پروژه‌های تحقیقاتی خاص مورد استفاده قرار می‌گیرند.

ج) پایگاه‌های داده برای شبیه‌سازی و مدل‌سازی

- ✓ پایگاه‌های داده‌ای که به طور خاص برای ذخیره‌سازی نتایج شبیه‌سازی‌های کامپیوتری طراحی شده‌اند، شامل داده‌هایی از شبیه‌سازی‌های دما، فشار، حرکت مولکولی و شبیه‌سازی‌های دینامیک مولکولی هستند.

چالش‌ها و اهمیت تحلیل داده‌ها در علم مواد

✓ داده‌ها به دلیل پیچیدگی‌های آن‌ها و حجم بالای اطلاعات، چالش‌هایی را به همراه دارد. برخی از چالش‌های عمده در تحلیل داده‌های مواد عبارتند از:

- **حجم زیاد داده‌ها**: در بسیاری از پروژه‌های علمی، حجم داده‌ها به‌قدری زیاد است که پردازش آن‌ها بدون استفاده از تکنیک‌های پیشرفته محاسباتی و ابزارهای تحلیلی غیرممکن است.
- **کیفیت و دقت داده‌ها**: داده‌های تجربی گاهی اوقات با خطاهای اندازه‌گیری یا نویز مواجه هستند که می‌تواند منجر به نتایج اشتباه شود. به همین دلیل، تمیز کردن و پردازش داده‌ها قبل از تحلیل ضروری است.
- **یکپارچگی داده‌ها**: بسیاری از داده‌های مواد از منابع مختلف می‌آیند و ممکن است با فرمت‌های متفاوت یا از مجموعه داده‌های غیرقابل مقایسه جمع‌آوری شوند. یکپارچه‌سازی این داده‌ها و تطبیق آن‌ها با یکدیگر یکی از چالش‌های مهم در این زمینه است.
- **داده‌های کم یا ناکافی**: در برخی از زمینه‌ها، به ویژه در مورد مواد جدید یا نادر، ممکن است داده‌های کافی برای پیش‌بینی خواص مواد موجود نباشد و این امر به مشکلات پیش‌بینی و مدل‌سازی منجر شود.

مدیریت و نمایش داده‌ها

- ✓ داده‌های معمولاً به صورت خام و غیرقابل استفاده به طور مستقیم برای تجزیه و تحلیل و مدل‌سازی در دسترس هستند.
- ✓ پاک‌سازی داده‌ها، ساماندهی و نمایش داده‌ها از مراحل اساسی در تحلیل داده‌های مهدسی و علم مواد است که بر دقت، سرعت و کارایی نتایج تحقیقات تأثیر می‌گذارد.
- ✓ با استفاده از ابزارها و روش‌های مناسب در این زمینه، می‌توان داده‌های پیچیده و حجیم را به طور مؤثر مدیریت کرد و از آن‌ها برای طراحی مواد جدید، پیش‌بینی خواص مواد و بهینه‌سازی فرآیندهای تولید بهره برد.
- ✓ در نتیجه، داشتن سیستم‌های داده‌ای سازمان‌دهی‌شده و قابلیت نمایش دقیق داده‌ها می‌تواند به محققان و مهندسان کمک کند تا تصمیمات بهتری بگیرند و پیشرفت‌های جدیدی در علم مواد به‌دست آورند.

مدیریت و نمایش داده‌ها

پاک‌سازی داده‌ها

- ✓ پاک‌سازی داده‌ها فرآیندی است که در آن داده‌های خام تصحیح یا اصلاح می‌شوند تا به صورت دقیق و قابل اعتماد برای تحلیل‌های بعدی مورد استفاده قرار گیرند.
- ✓ این فرآیند شامل شناسایی و اصلاح مشکلات مختلفی است که در داده‌ها وجود دارند، مانند مقادیر گم‌شده، داده‌های نادرست یا ناسازگار و اطلاعات غیرضروری. در بسیاری از مجموعه‌های داده، ممکن است برخی مقادیر به‌دلایل مختلف گم شوند.
- ✓ برای مثال، در هنگام جمع‌آوری داده‌ها ممکن است برخی آزمایش‌ها به دلایل فنی یا انسانی ناقص بمانند. شناسایی و مدیریت داده‌های گم‌شده یکی از **چالش‌های اصلی** در پاک‌سازی داده‌ها است.
- ✓ این کار معمولاً با استفاده از روش‌های مختلفی مانند پر کردن مقادیر گم‌شده با میانگین، میانه یا روش‌های پیچیده‌تر مانند مدل‌های پیش‌بینی انجام می‌شود.

مدیریت و نمایش داده‌ها

پاک‌سازی داده‌ها

- ✓ داده‌ها ممکن است حاوی مقادیر اشتباه یا ناسازگار باشند. به‌طور مثال، ممکن است واحدهای اندازه‌گیری مختلف یا فرمت‌های مختلفی برای داده‌ها استفاده شده باشد. در این صورت، این داده‌ها باید شناسایی و اصلاح شوند. به‌عنوان مثال، اگر برخی از داده‌ها در واحدهای مختلف مانند سانتی‌متر و متر قرار داشته باشند، باید به یک واحد استاندارد تبدیل شوند.
- ✓ داده‌های پرت (Outliers)، مقادیری هستند که به‌طور قابل توجهی از روند کلی داده‌ها منحرف شده‌اند و ممکن است به دلایل خطا یا شرایط خاص به وجود آمده باشند. شناسایی و مدیریت این داده‌ها اهمیت زیادی دارد، زیرا ممکن است تأثیر زیادی بر نتایج تجزیه و تحلیل‌ها داشته باشند. گاهی اوقات داده‌ها به طور تصادفی تکرار می‌شوند و باید شناسایی و حذف شوند تا از تحلیل‌های اشتباه جلوگیری شود.

مدیریت و نمایش داده‌ها

ساماندهی داده‌ها

- ساماندهی داده‌ها به معنای سازمان‌دهی و ساختاردهی داده‌ها به گونه‌ای است که به راحتی قابل دسترسی، تجزیه و تحلیل و اشتراک‌گذاری باشند.
- داده‌های به درستی سازمان‌دهی‌شده به پژوهشگران این امکان را می‌دهند که به راحتی از آنها در تحلیل‌ها، شبیه‌سازی‌ها و طراحی‌های خود استفاده کنند. برای ساماندهی داده‌ها، باید آنها را در قالب ساختارهای مشخص و قابل فهم قرار داد.
- به‌طور مثال، می‌توان داده‌ها را در قالب **جداول** یا **پایگاه‌های داده** با فیلدهای استاندارد سازمان‌دهی کرد تا دسترسی و استفاده از آنها آسان باشد. استانداردسازی داده‌ها به معنای تبدیل آن‌ها به فرمت‌ها و واحدهای یکسان است.
- برای مثال، برای داده‌هایی که مربوط به خواص مواد هستند، باید واحدهای استانداردی برای ویژگی‌هایی مانند استحکام، سختی و دما انتخاب شود. یکی از جنبه‌های مهم ساماندهی داده‌ها، ایجاد پایگاه‌های داده مرکزی و متمرکز است که بتوانند مجموعه‌ای از داده‌های مختلف را به طور هماهنگ ذخیره و مدیریت کنند. این پایگاه‌ها می‌توانند داده‌های مواد را از منابع مختلف جمع‌آوری کنند و آن‌ها را به صورت یکپارچه و قابل دسترسی برای محققان قرار دهند.

مدیریت و نمایش داده‌ها

نمایش داده‌ها

- ✓ نمایش داده‌ها به معنای **انتخاب و استفاده از ابزارها و تکنیک‌هایی** است که به کمک آنها می‌توان داده‌های پیچیده را به صورت بصری و قابل فهم ارائه داد.
- ✓ نمایش مناسب داده‌ها می‌تواند به محققان و مهندسان این امکان را بدهد که سریع‌تر الگوها و روابط موجود در داده‌ها را **شناسایی** کنند و از آنها برای **تصمیم‌گیری‌های** علمی و طراحی استفاده کنند.
- ✓ یکی از رایج‌ترین روش‌ها برای نمایش داده‌ها، استفاده از نمودارها و گراف‌ها است. ابزارهایی مانند matplotlib و seaborn در پایتون برای تولید نمودارهای مختلف مانند نمودارهای پراکندگی، هیستوگرام‌ها و نمودارهای دایره‌ای استفاده می‌شوند. این نمودارها می‌توانند به صورت بصری به تحلیلگران کمک کنند تا روابط میان متغیرها را بهتر درک کنند. نمودارهای حرارتی در تحلیل داده‌های پیچیده و چندبعدی مفید هستند.
- ✓ این نمودارها می‌توانند نشان‌دهنده شدت ارتباط میان ویژگی‌ها یا متغیرهای مختلف باشند و در شبیه‌سازی‌های مواد برای نمایش نتایج وابستگی‌های میان ویژگی‌های مختلف کاربرد دارند. در برخی از مسائل علمی، به‌ویژه در شبیه‌سازی‌های پیچیده و داده‌های نانو، نمودارهای سه بعدی می‌توانند به نمایش بهتر روابط میان متغیرها و تحلیل ویژگی‌های پیچیده‌تر کمک کنند