یادگیری ماشین نظارت شده

- ✓ اهداف
- ✓ آشنایی با ویژگی‌های روش‌های نظارت شده
- ✓ انواع روش‌های رگرسیون
- ✓ روش‌های ارزیابی رگرسیون
- ✓ روش‌های طبقه‌بندی
- ✓ شبکه‌های عصبی ساده
- ✓ حل مثال‌های پیاده‌سازی شده

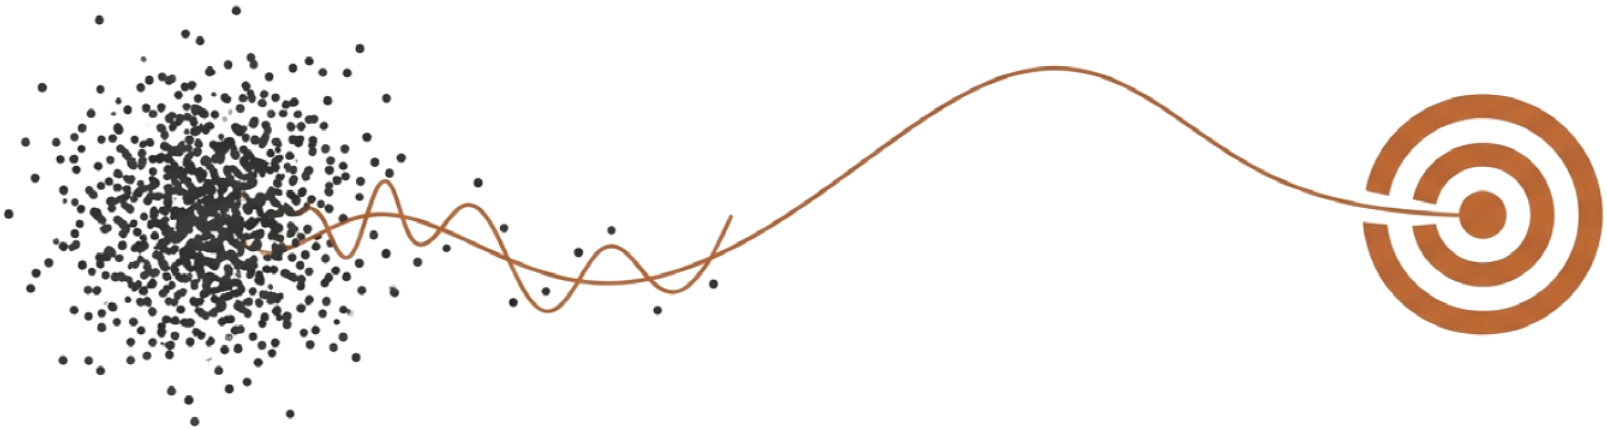


چرا یادگیری ماشین؟

یادآوری



- ✓ به رایانه‌ها امکان می‌دهد بدون برنامه‌نویسی صریح، الگوها را از داده‌ها یاد بگیرند.
- ✓ تمرکز اصلی: پیش‌بینی نتایج، دسته‌بندی، یا کشف ساختارهای پنهان.
- ✓ هدف: ساخت مدل‌هایی که بتوانند بر اساس داده‌های گذشته پیش‌بینی‌های دقیقی انجام دهند.



سفری از داده خام تا مدلی با پیش‌بینی‌های قابل اعتماد

پارادایم‌های (Paradigm) یادگیری ماشین

یادگیری نیمه‌نظارتی

ترکیب برچسب اندک و داده خام (Small Labeled + Large Unlabeled)

یادگیری بدون‌نظارت



با کشف ساختار (Structure) - Discovery یافتن الگوهای پنهان در داده خام.

یادگیری نظارت‌شده



با برچسب (Labeled) - یادگیری از مثال‌های دارای برچسب قطعی.

یادگیری برخط



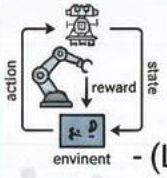
به‌روزرسانی با داده جریانی (Streaming Data Update) - یادگیری پیوسته و فوری.

یادگیری فعال



الگوریتم پرسش‌گر (Querying Algorithm) - درخواست برچسب برای داده‌های کلیدی.

یادگیری تقویتی



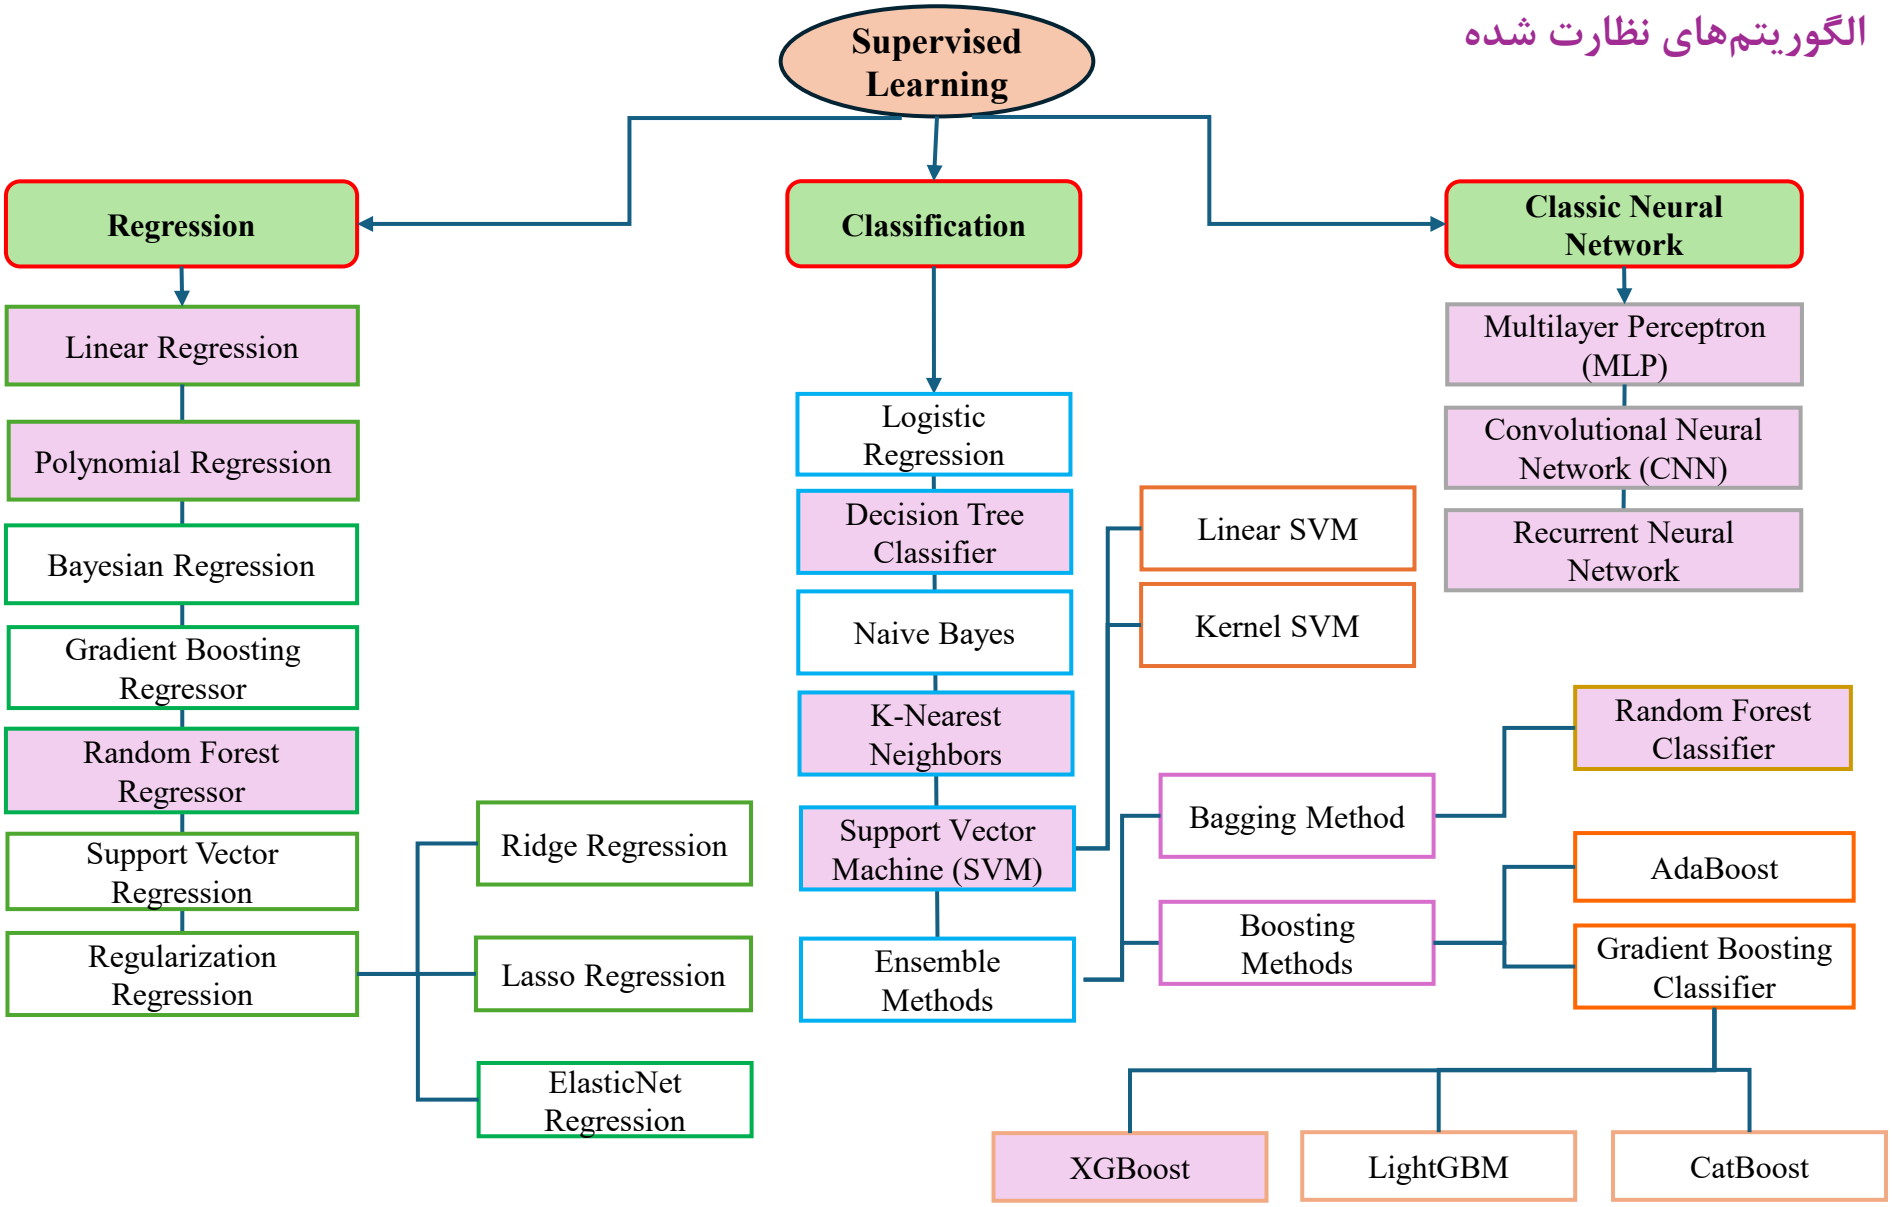
یادگیری از پاداش (Learning from Rewards) - بهینه‌سازی تصمیمات در تعامل.

یادگیری نظارت‌شده



با برچسب (Labeled) - یادگیری از مثال‌های دارای برچسب قطعی.

الگوریتم‌های نظارت شده

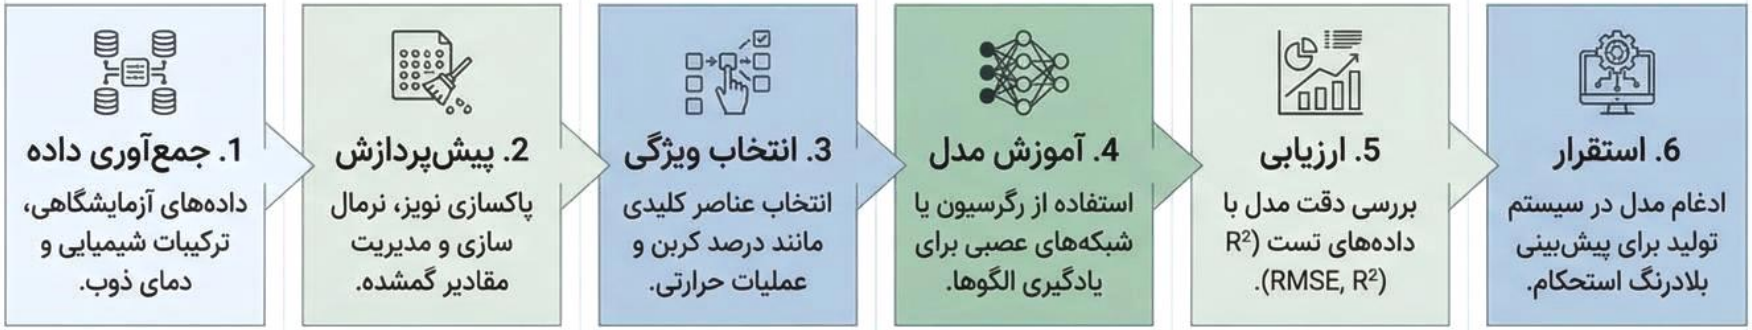


مراحل انجام یادگیری ماشین

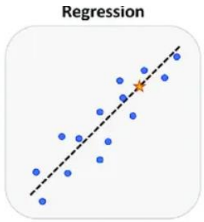


چرخه حیات یادگیری ماشین: مثال پیش‌بینی استحکام آلیاژ

مراحل استاندارد ML از داده خام تا استقرار مدل







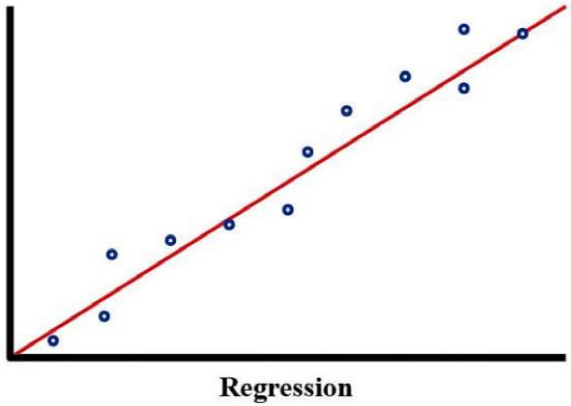
رگرسیون

رگرسیون فرآیندی است که برای پیش‌بینی مقادیر پیوسته بکار می‌رود.
مثلا استحکام یک ماده در بازه ۳۰۰ الی ۴۰۰ مگاپاسکال.
در رگرسیون، یک تابع ریاضی ایجاد می‌شود که رابطه بین مقادیر ورودی (متغیرهای مستقل) و مقدار خروجی (متغیر وابسته) را توصیف می‌کند.

$$Y = aX_1 + bX_2 + cX_3 + \cdots + D$$

$$Y = aX_1 + D = aX + b$$

یک رگرسیون **ساده خطی** است.
رگرسیون ساده: مدل شما فقط حاوی **یک** متغیر مستقل است.
اگر مساله شما حاوی چند متغیر مستقل باشد، مساله شما یک رگرسیون غیرساده یا چندگانه است.
الگوریتم‌های متنوعی می‌تواند مفهوم رگرسیون را پیاده‌سازی کنند. به عنوان مثال: DT و KNN و ... .



رگرسیون خطی

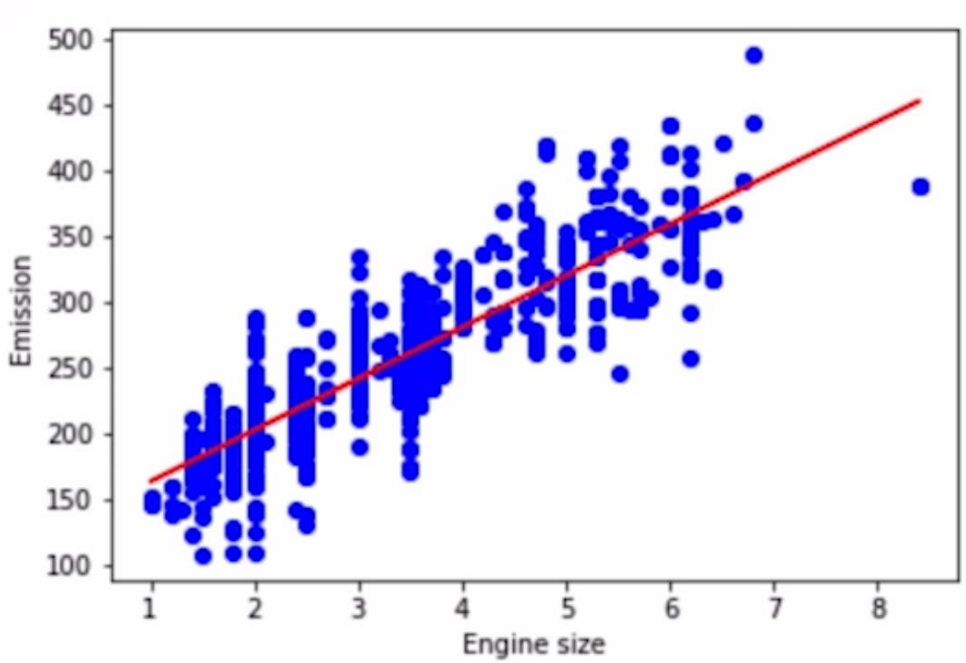
در رگرسیون خطی ساده که از رابطه زیر پیروی می‌کند، ثوابت a و b پارامتر مدل یا ضرایب معادله خط هستند.

$$Y = aX + b$$

از یک معادله خط در ریاضیات می‌دانید که ثوابت a و b به ترتیب شیب خط و عرض از مبدا خط برازش است.

سوال: بهترین خط در رگرسیون خط کدام خط است؟؟؟؟

سوال: معیار ارزیابی و تعیین بهترین خط چه چیزی است؟؟؟



رگرسیون خطی

پاسخ: خطی که برای هر ورودی کمترین میزان خطا را داشته باشد.

$$Error = (Y_{pred} - Y_{real})$$

$$Error = \sum (Y_{pred} - Y_{real})$$

اما خب برای داده‌های حجیم همواره این مقدار عددی بسیار بزرگ خواهد شد، لذا معیار خطا را تغییر داده می‌شود:

$$Error = \frac{1}{n} \sum (Y_{pred} - Y_{real})$$

که در واقع n تعداد داده‌های ورودی است.

اما مجددا عیب این نوع خطا این است که برای مقادیر پرت اثر ملموسی ایجاد نمی‌کند. برای برطرف کردن این مشکل کافی است معیار خطا را به شکل زیر تعریف کرد:

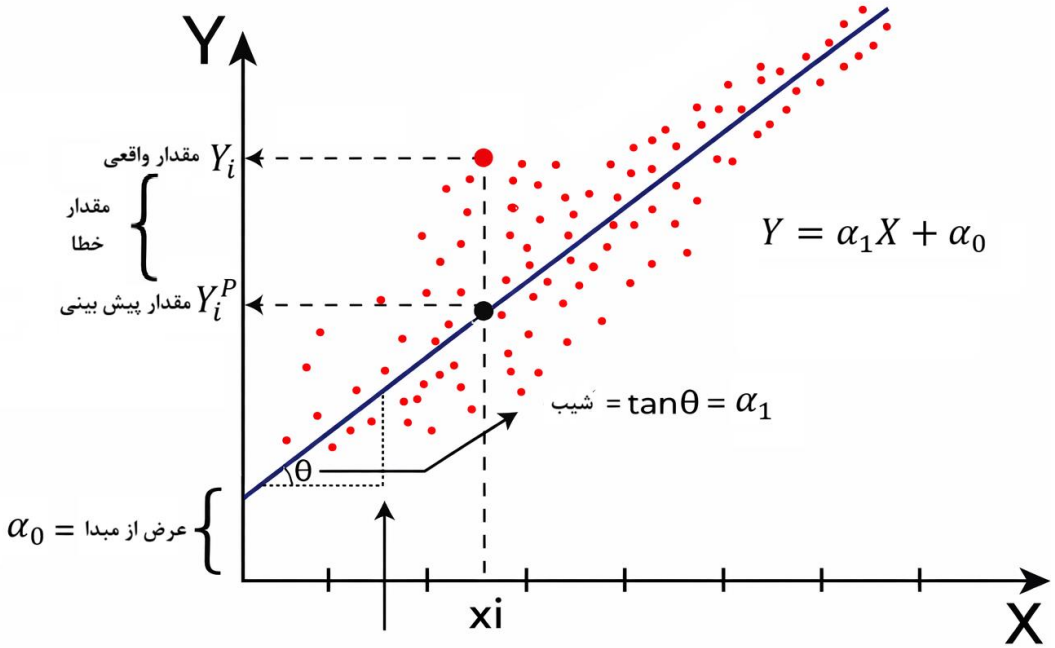
$$Error = \frac{1}{n} \sum (Y_{pred} - Y_{real})^2 = MSE$$

پس بهترین خط، خطی است که MSE (Mean Square Error) آن کمینه است.

در ادامه راه‌حل ریاضیاتی برای کمینه کردن خطای میانگین مربعات بررسی می‌شود.

رگرسیون خطی

- ✓ ماهیت اصلی رگرسیون بر یافتن یک تابع مناسب است که بتواند مقدار خروجی را از روی ورودی با کمترین خطا تعیین کند.
- ✓ هنگامی که مجموعه‌ای از داده در اختیار است، شامل ورودی‌هایی مثل دما، زمان، استحکام، عمر خستگی یا هر ویژگی دیگر، و خروجی‌هایی که متناسب با آن‌ها اندازه‌گیری می‌شوند، رگرسیون تلاش می‌کند توضیح دهد که چگونه این خروجی به ورودی‌ها وابسته است.
- ✓ معادله این خط طوری مشخص می‌شود که مجموع مجذور فواصل بین مقادیر واقعی و مقادیر پیش‌بینی (مقادیری که از خط به دست می‌آید) حداقل گردد. رگرسیون خطی علاوه بر توانایی پیش‌بینی، قابلیت تفسیرپذیری خوبی دارد.



رگرسیون خطی

نحوه محاسبه ثوابت یا پارامترهای مدل یا ضرایب معادله خط در روش رگرسیون خطی:

یادآوری از ریاضیات پایه:

شیب و عرض از مبدا یک خط مانند $y = ax_1 + b$ را با استفاده از روابط زیر می توان محاسبه نمود

	ENGINESIZE	CYLINDERS	FUELCONSUMPTION_COMB	CO2EMISSIONS
0	2.0	4	8.5	196
1	2.4	4	9.6	221
2	1.5	4	5.9	136
3	3.5	6	11.1	255
4	3.5	6	10.6	244
5	3.5	6	10.0	230
6	3.5	6	10.1	232
7	3.7	6	11.1	255
8	3.7	6	11.6	267

X_1 — ENGINESIZE

y — CO2EMISSIONS

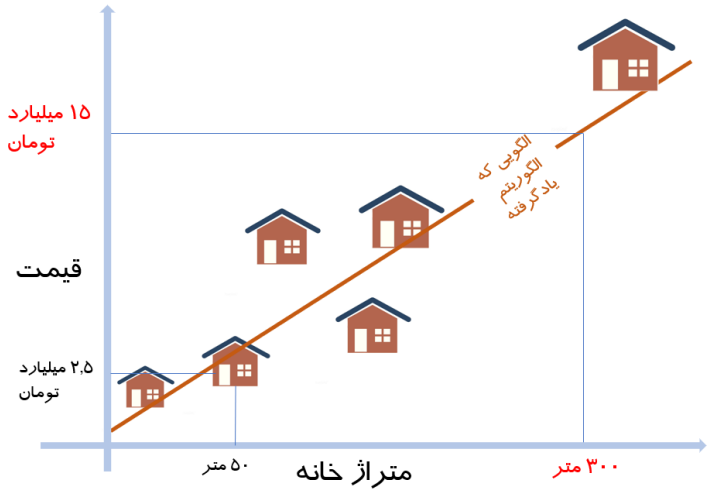
$$a = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^{n}(x_i - \bar{x})^2}$$

$$b = \bar{y} - a\bar{x}$$

رگرسیون چندگانه

- ✓ رگرسیون چندگانه در واقع همان رگرسیون خطی ساده است با این تفاوت که به جای نشان دادن همبستگی بین یک متغیر مستقل و یک متغیر وابسته، شما می‌توانید چندین متغیر مستقل را در نظر بگیرید.
- ✓ در واقع بر خلاف رگرسیون خطی ساده، تعداد ورودی‌ها یا ویژگی‌ها در نظر گرفته شده در این روش بیش از یک است و می‌توان تاثیر بسیاری از ویژگی را در مدل آموزش داد. به عنوان اگر قرار باشد میزان کرنش حاصل از چرخه حافظه‌شکلی یک پلیمر حافظه‌دار دو جهته را به عنوان خروجی بررسی کرد. پارامتر های زیادی مثل سطح تنش، نرخ گرمایش، نرخ سرمایش، چگالی اتصال‌دهنده‌های عرضی و وزن مولکولی پلیمر به عنوان ویژگی‌هایی است که باید در مدل لحاظ شود.

$$Y = \alpha_1 X_1 + \alpha_2 X_2 + \alpha_3 X_3 + \cdots + \alpha_n X_n + \alpha_0$$



مفهوم منظم‌سازی

- ✓ رگرسیون خطی فرض می‌کند داده‌ها فاقد هم‌خطی چندگانه (Multicollinearity) است (حالتی است که در آن دو یا چند متغیر مستقل (ویژگی) در یک مدل رگرسیونی همبستگی شدید با یکدیگر دارند هستند) و نویزی در آن‌ها وجود ندارد، اما در داده‌های دنیای واقعی معمولاً با تعداد زیادی ویژگی، نویز، داده‌های پرت و مسائل دیگری از این دست مواجه می‌شویم و دقیقاً به همین دلیل است که به منظم‌سازی (Regularization) نیاز است.
- ✓ منظم‌سازی روش آماری است که با افزودن یک جمله‌ی جریمه به تابع هزینه‌ی مدل، خطاهای ناشی از بیش‌برازش (Overfitting) روی داده‌های آموزشی را کاهش می‌دهد؛ این کار باعث می‌شود مدل‌هایی با ضرایب بسیار بزرگ و پیچیدگی بالا جریمه شوند و در نتیجه، مدل به سمت راه‌حل‌های ساده‌تر و تعمیم‌پذیرتر سوق پیدا کند، به‌طوری‌که منظم‌سازی به بهبود عملکرد مدل روی داده‌های دیده‌نشده کمک کرده و پایداری کلی آن را افزایش می‌دهد.

دو روش عمده منظم‌سازی:

- ❑ رگرسیون ریج (Ridge Regression) یا منظم‌سازی (L2)
- ❑ رگرسیون لاسو (Lasso Regression) یا منظم‌سازی (L1)

رگرسیون ریج و لاسو

- ✓ **یادآوری**: در مدل رگرسیون خطی، برای پیش بینی درست مقادیر از یک تابع خطا استفاده شده که به طور معمول این تابع مجموع مربعات خطا را کمینه می‌کنند.
- ✓ رگرسیون ریج (Ridge) که یک نوع رگرسیون خطی است از ترکیب تابع مجموع مربعات خطا و مقدار **جریمه** هر پارامتر، یک تابع جدید ایجاد می‌شود که به منظور پیش بینی مقادیر پارامترهای مدل رگرسیونی استفاده می‌شود.
- ✓ در واقع رگرسیون ریج با اضافه کردن یک جریمه به تابع خطا، از بزرگ شدن بیش از حد ضرایب جلوگیری می‌کند.
- ✓ این کار منجر به کاهش واریانس مدل می‌شود و آن را در برابر داده‌های جدید و نادیده مقاوم‌تر می‌سازد.
- ✓ در مقابل رگرسیون لاسو (Lasso) هم یکی از روش‌های رگرسیون خطی است که به منظور حل مشکلات داده‌های بزرگ و جلوگیری از بیش‌برازش (Overfitting) استفاده می‌شود.
- ✓ واژه‌ی Lasso برگرفته از عبارت Least Absolute Shrinkage and Selection Operator است که به معنای کوچک‌سازی و انتخاب متغیر با استفاده از مقدار مطلق کمینه است.
- ✓ این مدل در مسائلی به کار می‌رود که در آن‌ها تعداد متغیرهای توضیحی (ویژگی‌ها) بسیار زیاد است و نیاز به انتخاب زیرمجموعه‌ای از این ویژگی‌ها وجود دارد. متغیرهای مهم انتخاب می‌شوند.

منظم‌سازی L2

✓ **رگرسیون ریج با افزودن یک جریمه‌ی مربعی به ضرایب مدل عمل می‌کند:**

$$\text{Loss Function} = RSS + \lambda \sum_{i=1}^{p} \beta_i^2$$

که در آن RSS همان مجموع مربعات باقی‌مانده‌ها (Residual Sum of Squares) است و پارامتر λ شدت این جریمه را کنترل می‌کند، به‌طوری‌که هرچه مقدار آن بزرگ‌تر باشد، ضرایب بیشتر کوچک می‌شوند و مدل ساده‌تر و پایدارتر خواهد شد.

زمانی از ریج استفاده می‌کنیم که بخواهیم همه‌ی متغیرها در مدل باقی بمانند اما پیچیدگی مدل کاهش یابد، مشکل هم‌خطی چندگانه وجود داشته باشد و تفسیرپذیری ضرایب در اولویت اصلی ما نباشد.

منظم‌سازی L1

- ✓ **رگرسیون لاسو از قدر مطلق ضرایب در جمله‌ی جریمه استفاده می‌کند و باعث می‌شود برخی از ضرایب دقیقاً به صفر برسند؛ به این ترتیب، این روش به‌صورت خودکار انتخاب ویژگی انجام می‌دهد.**

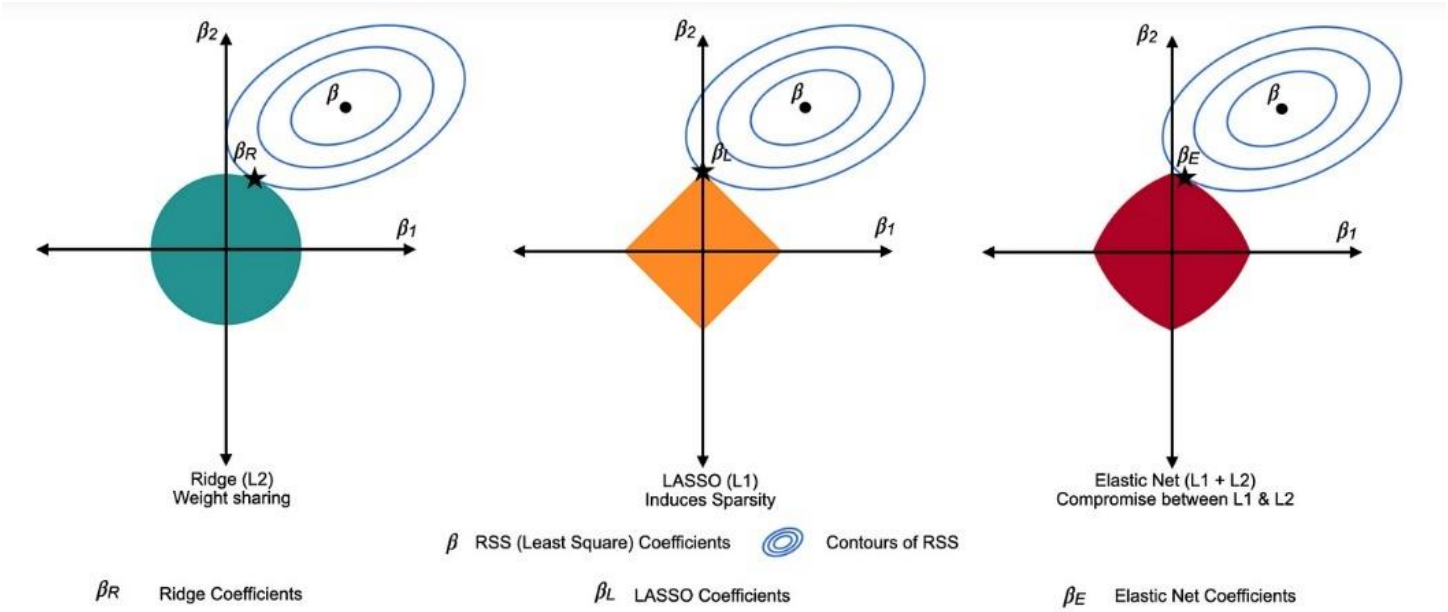
$$\text{Loss Function} = RSS + \lambda \sum_{i=1}^{p} |\beta_i|$$

- ✓ تابع هزینه (Loss Function) تابعی است که مدل تلاش می‌کند آن را کمینه کند تا بهترین ضرایب به دست آید. β_i ضریب ویژگی iام در مدل است. λ (پارامتر منظم‌سازی) شدت جریمه روی ضرایب را کنترل می‌کند. p تعداد کل ویژگی‌ها (متغیرهای مستقل). همچنین RSS یا مجموع مربعات باقیمانده‌ها میزان خطای مدل را اندازه می‌گیرد.
- ✓ از لاسو زمانی استفاده می‌کنیم که بخواهیم ویژگی‌های مهم را انتخاب کرده و بقیه را نادیده بگیریم، مجموعه‌داده شامل متغیرهای زیادی باشد که همه‌ی آن‌ها اهمیت یکسانی ندارند و در عین حال به مدل‌های ساده‌تر و قابل‌تفسیرتر اهمیت بدهیم.

سوال؟؟؟؟؟؟؟؟؟؟؟؟؟؟؟؟

- ✓ **وقتی می‌توان هر دو را با هم داشت، چرا بین ریج و لاسو یکی را انتخاب کنیم؟**
- ✓ الاستیک‌نت (ElasticNet) با ترکیب هم زمان جریمه‌های L1 و L2 این امکان را فراهم می‌کند و مزایای هر دو روش را در یک مدل واحد ارائه می‌دهد.

$$\text{Loss Function} = RSS + \lambda_1 \sum_{i=1}^{p} |\beta_i| + \lambda_2 \sum_{i=1}^{p} \beta_i^2$$



ارزیابی مدل

- ✓ نیاز به ارزیابی و بررسی این که چقدر می‌توان به مدل اعتماد کرد یک امر ضروری و مهم است.
- ✓ این ارزیابی را می‌توان در ساده‌ترین حالت به دو روش انجام داد:
- ✓ ۱- آموزش و آزمون روی همان داده.
- ✓ ۲- تقسیم داده‌های آموزش و آزمون (۲۰-۸۰) یا (۳۰-۷۰).
- ✓ در روش اول یادگیری با دقت بالایی انجام می‌شود، اما به این مفهوم نیست که مدل خوبی و قابل اعتمادی ارائه شده است.
- ✓ زیرا مدل بصورت جزئی و برای تک تک ورودی‌ها جواب‌ها و پیش‌بینی‌ها را حفظ کرده و به اصطلاح مدل دچار بیش‌برازش شده است.
- ✓ مثال: استاد ۲۰ سوال به دانشجوها داده و دانشجو هم همه داده‌ها (سوالات) را حفظ کرده است، آزمون از همین داده‌ها با مشکل بیش‌برازش مواجه است و دانشجو بدرستی ارزیابی نمی‌شود.
- ✓ در روش دوم از همان ابتدا بطور فرضی ۸۰ درصد ورودی‌ها را برای آموزش استفاده کرده و ۲۰ درصد را برای آزمون استفاده می‌شود. در واقع بر اساس این الگوریتم مدل برای قابل اعتماد بودن با داده‌های ندیده از همان مجموعه بررسی می‌شود.

ابزارها و تعاریف ریاضی و آمار برای ارزیابی عملکرد مدل

۱- خطای قدر مطلق میانگین

$$Mean\ Absolute\ Error = MAE = \frac{1}{n}\sum_{i=1}^{n}\left|y_i^{real} - y_i^{pred}\right|$$

۲- خطای مربع میانگین

$$Mean\ Squared\ Error = MSE = \frac{1}{n}\sum_{i=1}^{n}\left(y_i^{real} - y_i^{pred}\right)^2$$

۳- خطای ریشه مربع میانگین

$$Root\ Mean\ Squared\ Error = RMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n}\left(y_i^{real} - y_i^{pred}\right)^2}$$